



文章

基于注意机制和特征融合的多标签眼底图像分类

李振伟*, 徐梦颖, 杨晓丽, 韩艳琪

河南科技大学医学技术与工程学院, 河南洛阳 471032;200320221486 @stu.haust.edu.cn
(M.X.);yangxiaoli39@163.com(X.Y.);210321221641 @stu.haust.edu.cn (Y.H.)

*通信:9903137@haust.edu.cn

摘要:眼底疾病如不及时诊断和治疗, 可导致双眼视力不可逆丧失。由于眼底疾病的复杂性, 眼底图像包含两种或两种以上疾病的概率极高, 而现有基于深度学习的眼底图像分类算法在多标记眼底图像中诊断准确率较低。本文采用基于注意机制和特征融合的神经网络算法模型, 提出了一种基于双眼眼底图像的眼底疾病多标签分类方法。该算法突出双眼眼底图像中的细节特征, 然后将其输入到具有注意机制的 ResNet50 网络中, 提取眼底图像病变特征。该模型通过特征融合获得双目图像的全局特征, 并使用 Softmax 对多标签眼底图像进行分类。利用 ODIR 双目眼底图像数据集评估网络分类性能并进行消融实验。该模型的后端是 Tensorflow 框架。通过对测试图像的实验, 该方法的准确率、精密度、召回率和 *F1* 值分别达到了 94.23%、99.09%、99.23%和 99.16%。

关键词:注意机制;深度学习;特征融合;图像分类;眼底图像



引文:李, z;徐,mc杨,x;韩勇。基于注意机制和特征融合的多标签眼底图像分类。《微机械》, 2022,13,947。 <https://doi.org/10.3390/mi13060947>

学术编辑 :Melania Paturzo

收稿日期:2022 年 5 月 27
日接收日期:2022 年 6 月
13 日发布日期:2022 年 6
月 15 日

出版商注:MDPI 对已出版的地图和机构从属关系中的管辖权要求保持中立。



版权所有:©2022 by 作者。被许可方 MDPI, 巴塞尔, 瑞士。本文为开放获取文章, 遵循知识共享署名(CC BY) 许可 (<https://creativecommons.org/licenses/by/4.0/>) 的条款和条件进行分发。

1.介绍

眼底图像被眼科医生和计算机辅助诊断用来检测眼底疾病, 如糖尿病视网膜病变、青光眼、年龄相关性黄斑变性、白内障、高血压和近视。近年来, 随着计算机辅助诊断的准确性提高, 眼科医生逐渐采用计算机辅助诊断。该系统帮助医生进行部分诊断, 节省了医生和患者的时间和精力[1-3]。

早期发现眼底疾病对于患者避免失明至关重要。当对单张眼底图像进行三种颜色通道分析时, 眼底异常可以指示不同类型的疾病。由于眼部疾病的复杂性和相互独立性, 患者通常在每只眼睛中出现不同的眼部疾病。图 1 显示了右眼而非左眼糖尿病视网膜病变患者的左右眼底图像, 图片取自 ODIR 数据集[4]。大多数眼底图像研究的重点是分割眼底结构或检测某些眼底疾病的异常[5,6]。因此, 在眼底图像上对整个范围的疾病进行分类的能力对于未来诊断系统的发展至关重要。

基于融合图像处理和深度学习原理, 眼底图像的增强[7]、分割[8-10]和分类[11,12]等领域的各种算法都得到了发展。深度学习算法可以得到充分的训练, 并且对于图像较多的数据集不太容易出现过拟合, 测试结果的准确率可以超过 95%。多标签眼底图像分类的根本问题是数据不足, 这阻碍了模型的有效训练。二是病变较为明显的眼底图像, 如青光眼等发展较晚的疾病

在比较明显的病变出现之前，都比较容易识别，而且分类准确率明显较低。



图 1所示。ODIR 数据集的图片。(a)无疾病。(b)糖尿病视网膜病变和近视。

本研究提出了一种基于 ResNet 注意机制的双目眼底图像特征融合分类算法。该系统以双目眼底图像为输入，并添加一个注意机制，以全局、多标签的方式对疾病进行分类。通过对原始图像进行增强处理，解决了眼底图像异常模糊分类准确率低的问题。采用数据增强和批处理方法对数据进行训练，可以解决样本分布不均匀的问题。

1.1.眼底图像的分类

目前，大多数眼底图像分类挑战都集中在识别有或没有糖尿病视网膜病变[13]、近视[14]、青光眼[15]、年龄相关性黄斑变性[16]和其他眼部疾病的单一疾病。Gour 等人[17]使用单张眼底图像，利用迁移学习模型开发了卷积神经网络，实现了对多标签图像的高分类准确率。使用 SGD 对网络进行优化，将训练集准确率从 85.25%提高到 96.49%。然而，对于含有青光眼的眼底图像，分类准确率较低;原因之一是这些疾病的早期病变差异性不显著，在分类时不易被发现。其次，该数据集的数据明显少于其他疾病图像，使得模型在对这些疾病进行分类时对过拟合很敏感。Joon Yul Choi 等人[18]发现类的数量对分类性能有显著的影响。本研究使用 VGG-19 网络对三种眼底图像进行分类，当分类数增加到 5 个时，准确率下降到 41.9%。因此，应该尽快解决的关键问题是如何处理测试数据集使其均匀分布，以及如何训练高性能神经网络以提高眼底图像对每个疾病类别的分类精度。

1.2.图像增强

一个主要的挑战是平均正样本和负样本分布，增强图像质量以提高分类精度。分类模型中输入模块的数量会影响网络的性能。图像分布不均匀的问题在多标签数据中很常见。数据上采样方法，对图像进行旋转、翻转、裁剪等操作，以增加样本不足的数据集。迁移学习方法，通过在大型 ImageNet 图像数据集上训练获得权值参数，使用预训练的权值更容易获得最优结果。Luquan 等人[19]使用迁移学习将准确率从 62.82%提高到 75.16%，但该模型对于小数据集的图像类容易出现过拟合。第三，通过改变底层网络，模型可以表现得更好，即使是小样本，Wang 等人[20]使用 Vgg16 对多标签眼底图像进行分类，准确率达到 86%，改用 effentnetb3 将准确率提高到 90%。

1.3.注意机制

图像增强解决了样本分布不均匀的问题，但复杂的眼底病变，如微动脉瘤和出血，仍然难以识别。浅层神经网络学习图像的纹理特征;随着网络的加深，它学习图像的语义信息。丰富的语义信息可以提高网络的分类性能。包括注意力模块可以让图像正确学习病变的空间位置信息。该模块模仿人类在复杂情况下寻找重要区域，在各种视觉任务中有应用[21]，包括图像分类、目标识别、图像分割和面部识别。如图 2 中的相关性所示，它可以根据数据域分为六种类型:通道、空间、时间和分支注意力机制，以及通道和空间注意力机制和空间和时间注意力机制。Hu 等人[22]提出了 SENet 通道注意网络，其基础包括一个挤压和激励(SE)模块。SE 模块可以收集数据信息，捕获通道间的关系，并增强表示。但是，它的缺点是无法捕获复杂的全局信息，模型复杂度较高。Sanghyun Woo 等人[23]提出了卷积块注意模块(convolutional block attention module, CBAM)来改进全局信息挖掘。它连接了通道注意和空间注意力机制，使网络能够专注于特征及其空间位置。由于网络的轻量级设计，CBAM 也可以添加到任何现有的网络体系结构中。

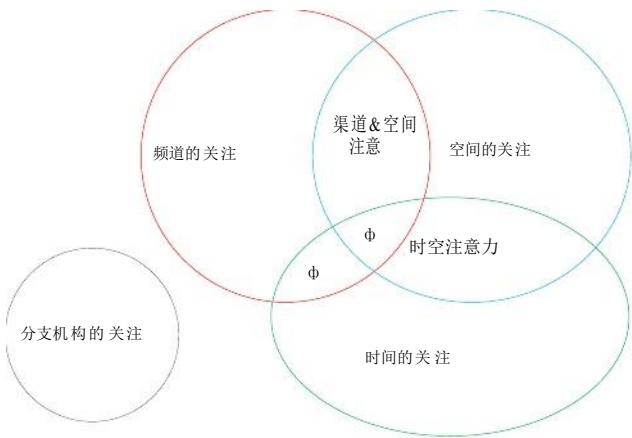


图 2。注意机制的分类(表示没有相关的分类)。

1.4.模型优化

当使用高性能模型作为基本分类网络时，总性能指标得到提高[24]。这是因为网络的预测能力与其对眼底图像特征的识别程度密切相关。为了处理输入的眼底图像，必须使用高性能的神经网络。多模型融合可以创建两个模型来提取特征向量，然后在融合过程中通过向量将它们连接起来，以提高分类精度。Wang 等人[20]使用 effentnet 分析了基于模型融合的双目眼底图像分类，提取特征，然后将特征输入到分类器中进行分类，这是一种准确率为 90%的两阶段分类技术。一般来说，网络越深，分类效果越好。但是，网络越深，过度拟合的风险就越大。ResNet 通过加入残差模块扩展了网络优化，从而提高了分类性能[25,26]。此外，在深度学习中，数据集大小对于确定分类性能非常重要。然后在巨大的 ImageNet 数据集上加载预训练权值，在目标数据集上进行训练，通过迁移学习获得合适的训练参数。Gour 等人[17]利用通过迁移学习训练的神经网络来训练双眼眼底图像。分类准确率

白内障疾病为 97%，青光眼疾病为 54%，分类准确率差异很大，导致模型置信度较低。

针对以上问题，本文重点设计了基于注意机制的双目特征融合眼底图像分类网络。为了解决数据不足导致的网络过拟合问题，对原始眼底图像进行图像增强和增强处理，并利用迁移学习提高模型的训练效率。通过融合 ResNet 和注意力模块提取双眼眼底图像的特征，增强了网络对细节的处理能力。在随后的实验中，通过对比分析和消融实验验证了模型的有效性。

2.材料与方法

为了对眼底疾病进行有效的分类，提出了一种基于注意机制和特征融合的双目眼底照片分类网络(双目眼底照片分类网络 BFPC-Net)，如图 3 所示。BFPC-Net 由图像增强模型(IAM)、剩余注意模块(RAM)和特征融合模块(FFM)三部分组成。该网络主要有两个特点:(1)增加了残差网络和注意力机制融合模块，使网络更加关注病灶特征信息，改善病灶与背景的特征差异;(2)增加了多模型融合模块，结合双眼眼底图像确定疾病类型，提高分类准确率。




图 3。BFPC-Net 模型。IAM:图像增强模型;RAM:剩余注意模块;FFM:特征融合模块。

BFPC-Net 以患者的双眼眼底图像作为输入，输出六种疾病类别、一种正常类别和一种其他类别。为了平均每个类的输入数量，BFPC-Net 从图像增强模块开始。为了提取浅层特征，通过使用 3 × 3 卷积层、批处理归一化层和 ReLU 激活层来增强图像通道的数量。RAM 模块是剩余注意模块，增强了网络深度，克服了梯度消失和梯度爆炸问题。由于使用双眼眼底图像，需要将两个网络提取的特征进行融合，然后通过 ReLU 激活层，使用 dropout 层和完全连接层来获得分类结果。

2.1.眼底图像数据集

ODIR 数据集来自北京大学眼病智能识别国际竞赛(ODIR-2019), 其中包括标签信息和视网膜眼底图像。

图 4 显示了每个标签的分布信息。数据集由 6392 张图像组成;44.95%为正常眼底图像, 55.05%为病变眼底图像, 而 25.16%的病变眼底图像来自糖尿病视网膜病变患者。




图 4. ODIR 数据集分布。正常(N)、糖尿病(D)、青光眼(G)、白内障(C)、年龄相关性黄斑变性(A)、高血压(H)、病理性近视(M)、其他疾病/异常(O)。

表 1 显示了对数据样本进行平衡后, 每种标签的原始图像和预处理图像的分布情况。

表 1. 图像预处理后的样本分布。

	原 始 图 像	预 处 理 图 像	训 练 集	测 试 集
N	2873	2873	2298	575
D	1608	1539	1231	308
G	284	1638	1310	328
C	293	1674	1339	335
一个	266	1560	1248	312

实验评估策略分为两部分:首先, 对所有类别的模型的整体准确率(accuracy, A)、精度(precision, P)、召回率(recall, R)和 *F1* 值进行评估。第二步, 对上述指标进行相同的评估

针对每个类。综合指标的比较研究为

评估模型的整体性能。

精度=
$$\frac{TP+TN}{TP+FP+TN+FN}$$
$$\frac{TP}{TP+FP}$$
$$\frac{TP}{TP+FN}$$

(1)

(2)

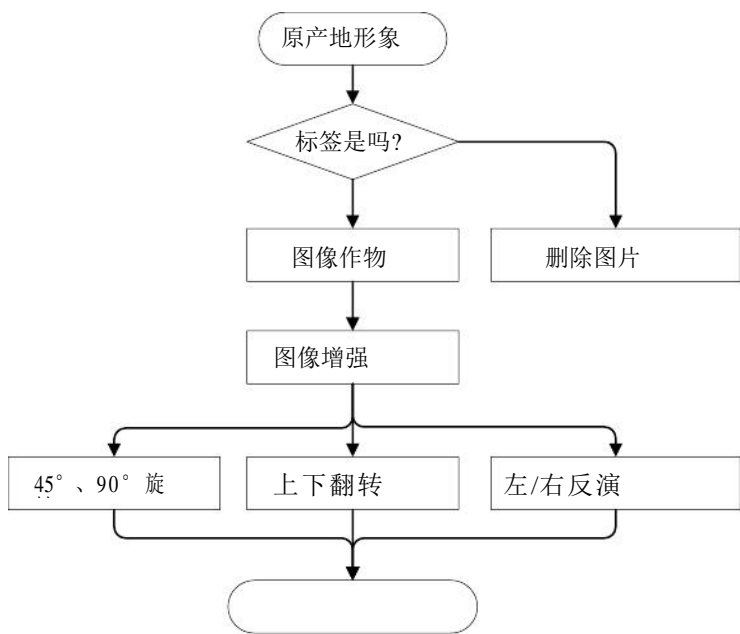
$$F1_{score} = \frac{2TP}{2TP + FP + FN}$$

(4)

式中， TP 表示正标签和正预测值， FP 表示负标签和正预测值， TN 表示负标签和负预测值， FN 表示正标签和负预测值。

2.2.图像增强模块

图像越大，包含的纹理和细节就越多，能够捕捉到的特征也就越好。然而，当图像大小超过特定阈值时，分类性能达到峰值，并且计算成本随着图像的增加而增加。该算法适用于图像增强模块(IAM)，该模块包括三个组成部分:图像归一化、图像加权增强和数据增强。图像预处理的细节如图 5 所示。



程。

图像加权增强可以表示为式(5)。

$$I_{weight} = I_{org} * \alpha + I_{blur} * \beta + \gamma$$

(5)

式中 $\alpha = 4$, $\beta = -4$, $\gamma = 128$, I_{org} 为原始图像, I_{blur} 为原始图像与高斯核卷积后的模糊图像。高斯模糊步骤如式(6)所示。

$$I_{blur} = I_{org} * kernal_{h \times w}$$

(6)

高斯核的大小为 $h = w = 63$, h 方向和 w 方向的值的标准差为 10。

数据增强过程的主要步骤是后续旋转、左/右反转和上/下翻转。图 6 描绘了结果。使用数据增强可以帮助缓解由于数据分布不平衡导致的过拟合和分类精度低的困难。




图 6。图像增强结果。

2.3. 剩余注意模块

该模型将残差架构与注意机制相结合，从双眼眼底图像中提取深层语义信息，架构如图 7 所示。给出图像增强特征映射 $F \in R(C \times H \times w)$ 作为输入。为了关注图像各通道之间的特征映射关系，通道注意图为 $U \in R(C \times 1 \times 1)$ 。加入空间注意图 $UO \in R(C \times H \times w)$ ，得到局部区域的空间关系。残差架构旨在通过合并输入 F 和 UO 来提高网络深度，然后由 ReLU 激活以产生输出 $M \in R(1 \times H \times w)$ 。Woo[20]等人使用的是 sigmoid 激活函数，而我们在研究中采用了 ReLU 函数作为激活函数，提高了模型的泛化能力。




图 7。剩余注意模块。

在通道注意模块中，设置了三个卷积层来捕捉通道之间特征的非线性关系。 $F \in R(C \times H \times w)$ 作为输入，依次推断出一个 1D 频道注意图，产生频道特征 $FO \in R(C \times H \times w)$ 。

通道注意力被设计为利用特征的通道间关系。平均池化通常用于聚合空间信息。Sanghyun Woo[23]使用了 average-pooling 和 max-pooling 来收集关于的信息

独特的对象特征可以推断出更精细的频道明智的注意力。我们认为平均池化可以有效地学习目标对象的范围，但最大池化会遗漏一些信息。平均池化过程产生了两个不同的空间上下文描述符。在密集层中使用这两个描述符来降低特征维数，并将结果馈送到非线性激活层中以获得 $U \in R$ 处的输出($C \times H \times W$)。如式(7)所示:

$$U = \sigma(FC(AvgPool(F')) + FC(AvgPool(F'))) \times F' \tag{7}$$

其中 $AvgPool(\bullet)$ 表示全局平均池化， $FC(\bullet)$ 表示全连接， $\sigma(\bullet)$ 表示 ReLU 激活。

空间注意模块关注眼底病变的位置信息。Zagoruyko 等人[27]证明了叠加池化操作能有效突出特征区域。空间注意模块的输入为 U ，输出为 $U0$ 。简而言之，空间注意力由式(8)计算得出:

$$U0 = Conv(MaxPool(AvgPool(U))) \times MaxPool(AvgPool(U)) \tag{8}$$

其中 $Conv(\bullet)$ 表示卷积， $MaxPool(\bullet)$ 表示全局最大池化。

将残差架构与注意机制合并的模块的输入是预处理图像与注意模块输出的组合，如式(9)所示:

$$M = U' + F \tag{9}$$

2.4. Feature Fusion Module

双目眼底图像通常包含一种或多种疾病，单纯检测单眼眼底图像无法提供对患者病情的全面分析。深度学习训练过程是寻找全局最优解的一种方式，而学习率等超参数往往会导致模型在某一点陷入局部最优解，导致模型停止优化。多模型融合策略可以帮助减少这一问题。通过构建基于双目特征的多模型特征融合模块 FFM，对模型输出特征进行融合，得到更好的结果。

如式(10)所计算，采用滑动平均方法对多模型特征进行合并:

$$p = \frac{1}{T} \sum_{(i=1)}^T w_i y_i \tag{10}$$

式中， T 表示模型个数，设为 2, w_i 表示单个模型的权重，分别设为 0.5、0.5, y_i 表示 预测值。

2.5. 损失函数

为了减少数据抖动并提高模型在测试集上的性能，在训练模型时使用标签平滑方法中的滑动平均方法对预测值进行处理。如式(11)所示:

$$y'_k = (1 - v) \times y_k + \frac{v}{K} \tag{11}$$

式中 y_0k 表示平滑后的第 K 个标签值， y_k 表示第 K 个标签的真实值， v 表示错误率并取 0.1 的值， K 表示类数，类标签总数为 8 个。

标签平滑处理后的损失函数可计算为:

$$Loss(y'_k, \hat{y}_k) = -\sum_{(k=1)}^K y'_k lg(\hat{y}_k) \tag{12}$$

其中， y_k 表示预测类的概率。

3.结果 与讨论系统规范

该模型使用 Keras 深度学习框架进行训练和测试, 在 Windows 10 Pro 系统上使用 NVIDIA CUDA 10.2 进行 GPU 加速。BFPC-Net 使用 Tensorflow 作为后端 Keras 框架, 使用 Adam 优化器减少损失, 学习率为 0.001,epoch 为 100。超参数配置如表 2 所示。

表 2。不同算法比较(%)。

配置	值
图像大小	256 × 256
损失函数	二进制 crossentropy
优化器	Adam
火车/测试	4/1
时代	One hundred.
批量大小	32
学习速率	0.001

3.2.实验结果与讨论

3.2.1.ODIR 数据集的实验结果分析

图 8 和图 9 显示了在训练模型以评估 BFPC-Net 分类性能时的模型拟合情况。如图所示, 模型快速拟合到最优, 并且模型上没有训练集和验证集的过拟合。表 3 显示, 在对比[20,28,29]研究在眼底图像分类方面的性能指标时, MCGS-Net 的准确率和召回率较低, 不能有效地对疾病图像进行分类。ResNet 增强了网络的深度, 以获取更详细的眼底图像进行分析, 其分类性能优于上述两种模型。Effi- cientNet 是一种轻量级网络, 模型参数较少, 提高了相关指标, 但指标仍然很低。在样本较少的情况下, 本文提出了 BFPC-Net

研究可以快速拟合模型, 达到较高的准确率。




图 8。BFPC-Net 的训练集和验证集损失。

表 3。不同算法对比(%)。

算法	精度	精度	回忆	F1 值
MCGS-Net [28]	-	65.88	61.60	89.66
EfficientNet [20]	92	71	66	89
ResNet [29]	95.47	95.41	94.22	94.75



图 9。BFPC-Net 训练集和验证集精度。

在类不平衡的情况下，每个类的高或低性能指标更好地反映了模型的整体性能。图 10 显示了 BFPC-Net 分类

在 ODIR 数据集上的 8 个类上的性能。该方法实现了改进的

在数据集中实现分类结果，可以对类产生更好的分类结果
使用更少的图像。

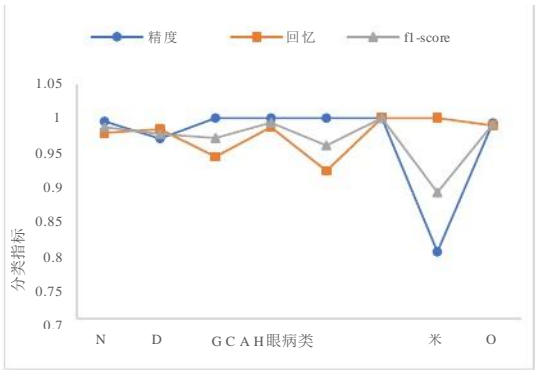


图 10。BFPC-Net 检测每种疾病的分类指标。

3.2.2.烧蚀实验结果分析

使用图像尺寸分别为 256×256 和 128×128 的图像进行训练，分类结果如图 11 所示。结果表明，在其他条件相同的情况下，图像越大，分类结果越好。




图 11。不同的 BFPC-Net 图像大小评价指标。

即使以 128×128 的图像作为输入，训练出的准确率、精密度和召回率都分别达到了 0.8942、0.9665 和 0.9660，这说明该模型对于低像素图像的分类效果同样出色。

将 BFPC-Net 分为基本网络(Baseline)和 Baseline + FFM 模型进行独立实验, 验证 IAM 模块和 FFM 模块对模型的整体贡献, 结果如表 4 所示。结果表明, 加入 FFM 模块后, 精度提高了 13.14%, 其他三个性能指标分别提高了 15.7%、20.87%和 18.37%。

表 4。图像尺寸为 256 × 256(%)的消融实验分析。

模型	精度	精度	回 忆	<i>F1</i> 值
基线	80.82	83.39	78.36	80.79
基线+ FFM	94.23	99.09	99.23	99.16

3.2.3. 模型性能分析

如表 5 所示, 与研究[30]方法相比, 在精度和参数方面, BFPC-Net 模型的精度提高了 5.52%, *F1* 值提高了 10.45%, 且参数比研究[30]中使用的 VGG16 模型少。

表 5所示。模型的性能分析。

算 法	准 确 率(%)	<i>F1</i> 值(%)	的 数量 引用(MB)
VGG16 [30]	88.71	88.71	16.29
BFPC-Net	94.23	99.16	12.79

4.结 论

使用 ODIR 数据集, 提出并评估了一种用于双目眼底图像分类的深度卷积神经网络架构。通过简单输入患者的双眼眼底图像, 该方法可以产生高置信度的眼底疾病分类。实验结果表明, BFPC-Net 结合图像增强、残差关注和特征融合等模块, 克服了眼底图像数据集小、疾病分类准确率低等问题。BFPC-Net 可以结合双眼眼底图像为患者提供全面的治疗方案。

未来可以使用更多类型的眼底疾病图像进行分类, 尤其是临床上的罕见疾病。这类问题的难点在于小样本数据分类的训练效果较差。而这类疾病的分类则更适合临床应用。

作者贡献 :Conceptualization, z.l.;数据管理, M.X.;形式分析, Y.H.;写作-原稿, M.X.所有作者已阅读并同意稿件的出版版本。

资助 :本研究得到河南省科技发展计划(202102310534)资助。

利益冲突:作者声明无利益冲突。

参考文献

1. 陈、T.-L.;王 j .;袁锋。用于视网膜疾病检测的人工智能深度学习辅助诊断系统的初步研究。 *Int。眼科学*, 2020,20,1452-1455。

2. 阿加沃尔, A.;Chakradar m;Bhatia,硕士;Kumar 先生;斯蒂芬,t;古普塔,” 栏目;Alsamhi,萨达姆政权;使用模糊推理系统和机器学习方法的糖尿病患者 COVID-19 风险预测。 *j . Healthc。工程学报*, 2022,1-10。 [[CrossRef](#)] [[PubMed](#)]

3.Chakradar m;阿加沃尔, A.;程,x;拉尼, a;Kumar 先生;使用机器学习的无创方法通过甘油三酯和 HDL-c 比值识别胰岛素抵抗。 *神过程。Lett.***2021**, 1-21。 ([CrossRef](#))

4.李,c;你们j .;他,j .;王,美国;乔,y;顾林。基于配对彩色眼底照片的多标签眼病自动检测的密集相关网络。2020 年 IEEE 第 17 届国际生物医学成像研讨会(ISBI)论文集, 爱荷华市, IA, USA, 2020 年 4 月 3-7 日;1 - 4 页。

5. 歌,w;曹,y;乔,z;问:王;杨,j j. 一种改进的半监督学习方法用于白内障眼底图像分类。IEEE 第 43 届年度计算机软件与应用会议 (COMPSAC)论文集, Milwaukee, WI, USA, 2019 年 7 月 15-19 日;362 - 367 页。
6. 曹,h;黄 Y.H.;钟 J.K.;李,K.B.;公园,J.S.二;金、H.-G;使用眼底照片和卷积神经网络进行青光眼分期分类的深度学习集成方法。《*咕咕叫。眼科学*》, 2021,46,1516-1524。([CrossRef](#))
7. Sahu,美国;辛格 H.V.;库马尔,b;辛格 A.K.;基于图像处理的青光眼自动检测技术及其降噪作用:技术综述。在*多媒体信息安全手册:技术和应用程序*;Springer: Berlin/Heidelberg, Germany, 2019;359 - 375 页。
8. Fraz M.M.;雷马格尼诺, P.;A.霍普;Uyyanonvarab;那么 Rudnicka 境;欧文,C.G.;血管分割方法在视网膜图像-调查。第一版。方法程序*生物医学*, 2012,108,407-433。([CrossRef](#)) [[PubMed](#)]
9. Almazroa, a;伯尔曼,r;Raahemifar k;用于青光眼图像检测的视盘和视杯分割方法:综述。[j] .*眼科杂志*, 2015,2015,1-28。([CrossRef](#)) [[PubMed](#)]
10. Madhu g;Govardhan, a;拉维, v;Kautish,美国;斯, “狗屁” ;乔杜里,t;Kumar, M. DSCN-net:用于疟疾寄生虫检测自动诊断的深度暹罗胶囊神经网络模型。*Multimed. 工具应用*, 2022,1-23。([CrossRef](#))
11. 阿明 j ;谢里夫,m;Yasmin, M.糖尿病视网膜病变检测的最新进展综述。*科学杂志*, 2016,1-20。([CrossRef](#))
12. Thakur.;Juneja, M.视网膜图像诊断青光眼的分类方法综述。In *Advanced Computing and Communication Technologies*;Springer:柏林/海德堡, 德国, 2018;91 - 99 页。
13. 克里,响亮的;克莱夫·d·;嗯, R.V.;Ramteke P.B.;Koolagudi, S.G.一种基于深度卷积神经网络的糖尿病视网膜病变分类的迁移学习方法。IEEE 印度理事会国际会议(INDICON)论文集, 哥印拜陀, 印度, 2018 年 12 月 16-18 日;1 - 6 页。
14. 湾,c;李,h;曹、G.-F;江,问:;杨,W.-H. 一种高度近视人工智能风险分类方法。*j .中国. 医学杂志*, 2021,10,4488。([CrossRef](#))
15. 郭,f;李,w;赵,x;邹斌. 基于语义特征图引导的青光眼筛查方法。*j .第一版.-辅助 Des. Comput. 图*. 2021,33,363-375。([CrossRef](#))
16. Grassmann f;Mengelkamp), j .;Brandl c;Harsch,美国;齐默尔曼,主机;Linkohr b;彼得斯,a;Heid,即时消息;手掌,c;Weber, B.H.一种用于预测年龄相关性眼病的深度学习算法研究彩色眼底摄影中年龄相关性黄斑变性严重程度量表。《*Ophthalmology*》2018,125,1410-1420。([CrossRef](#)) [[PubMed](#)]
17. 你, N.;Khanna, P.基于迁移学习的卷积神经网络的多类多标签眼科疾病检测。*生物医学. 信号的过程. 控制*. 2021,4,102329。([CrossRef](#))
18. 崔 J.Y.;Yoo T.K.;搜索引擎优化,j. ;夸克,J.J.;嗯,总时间;Rim, T.H.多分类深度学习神经网络对视网膜图像进行分类:采用小型数据库的试点研究。*PLoS ONE*2017, 12, e0187336。([CrossRef](#)) [[PubMed](#)]
19. 陆,问:;他,c;陈,j .;分钟,t;刘涛. 一种具有两阶段迁移学习的多标签分类模型。*数据肛门."*。发现。2021,5,91-100。
20. 王,j .;杨,l;霍,z;他,w;罗杰. 基于 Efficient Net 的眼底图像多标签分类。*IEEE Access*2020, 8, 212499-212508。([CrossRef](#))
21. 郭,M.H.;徐、T.-X;刘,j j. 刘志宁;江、P.-T;亩,T.-J. 张,工程学系;马丁,水银血压计;程、m m;胡,S.-M. 计算机视觉中的注意机制:综述。*arXiv*,2022, arXiv:2111.07624。([CrossRef](#))
22. 胡,j .;沈,l;挤压与激励网络。*arXiv*,2017, arXiv:1709.01507。
23. 哇,美国;公园,j .;李,J.-Y. ;Kweon, I.S. CBAM:卷积块注意模块。在 Proceedings of the Computer Vision-ECCV 上, 德国慕尼黑, 2018 年 9 月 8-14 日;p. 11211。
24. 居,c;Bibaut, a;Van Der Laan, M.深度卷积神经网络用于图像分类的集成方法的相对性能。j.: *统计学家*. 2018,45,2800-2818。([CrossRef](#))
25. 王,f;江,m;钱,c;杨,美国;李,c;张,h;王欣. 图像分类的残差注意网络。2017 年 IEEE 计算机视觉与模式识别会议(CVPR)论文集, 檀香山, HI, USA, 2017 年 7 月 21-26 日。
26. Veit, a;威尔伯,m;残差网络是相对浅网络的指数集合。*arXiv*,2016, arXiv:1605.06431。
27. Zagoruyko,美国;关注注意力:通过注意力转移提高卷积神经网络的性能。*arXiv*,2016, arXiv:1612.03928。
28. 林,j .;Cai,问:;基于图卷积网络 and 自监督学习的眼底图像多标签分类。*IEEE Signal Process. 通讯*, 2021,99,454-458。([CrossRef](#))
29. 谢,h;曾,x;Lei, h;杜,j .;王,j .;张,g;曹,j .;王、t;雷 B.基于 SLO 图像的眼底疾病分类交叉关注多分支网络。*Med. Image 肛管*. 2021,71,102031。([CrossRef](#)) [[PubMed](#)]
30. 乔迪,林祖嘉;Manuel N.D.R.J.;Carles, V.R.眼部疾病通过深度学习架构的智能识别;Catalunya Oberta 大学:巴塞罗那, 西班牙, 2019;1 - 114 页。